

Trabajo Práctico 1 – Panorámica

Matias Lein, Ignacio Vargas

Universidad de San Andrés

mlein@udesa.edu.ar ivargasfernandez@udesa.edu.ar

Resumen—Este trabajo práctico implementa un pipeline para la construcción de una panorámica a partir de tres imágenes. Se emplearon técnicas de detección de puntos clave (SIFT), supresión adaptativa de no-máximos (ANMS), emparejamiento de descriptores con prueba de razón de Lowe, y estimación de homografías mediante DLT y RANSAC. Finalmente, se realizó el warping de imágenes y blending para generar la panorámica final.

I. INTRODUCCIÓN

La construcción automática de panorámicas es un problema clásico en visión por computadora que consiste en combinar múltiples imágenes parciales de una misma escena en una sola vista coherente. El desafío central reside en identificar correspondencias confiables entre puntos de distintas imágenes y, a partir de ellas, estimar las transformaciones geométricas necesarias para alinearlas en un marco común. Cuando la escena puede modelarse bajo una transformación proyectiva, esta relación se describe mediante una homografía.

En este trabajo se desarrolló de forma incremental el pipeline típico para el *image stitching*, implementando cada una de sus etapas clave: detección y descripción de puntos característicos (SIFT), selección adaptativa de características (ANMS), emparejamiento mediante distintas estrategias (validación cruzada y prueba de razón de Lowe), estimación de homografías tanto manual con DLT como robusta con RANSAC, y finalmente el warping y blending de las imágenes para obtener la panorámica.

El objetivo principal fue analizar el impacto del uso de RANSAC en la estimación de homografías, comparando resultados frente al enfoque directo con DLT, y evaluando cómo la supresión de outliers mejora la estabilidad geométrica y la calidad visual de la panorámica resultante.

II. MÉTODO

El procedimiento se dividió en las siguientes etapas:

II-A. Detección de características con SIFT

Para la detección de puntos clave se utilizó el algoritmo *Scale-Invariant Feature Transform* (SIFT), el cual permite identificar regiones de interés que son invariantes a cambios de escala, rotación e iluminación.

El detector se basa en la pirámide de *Diferencias de Gaussianas* (DoG), definida como:

$$D(x, y, \sigma) = (G(x, y, k\sigma) - G(x, y, \sigma)) * I(x, y)$$

donde G es un filtro Gaussiano y I la imagen. Los puntos clave se localizan como máximos o mínimos locales en esta función.

A cada keypoint se le asocia un descriptor construido a partir de histogramas de gradientes, lo que facilita su comparación con puntos de otras imágenes.

II-B. ANMS

Tras la detección inicial con SIFT, la cantidad de puntos clave puede ser muy elevada y concentrarse en regiones con alto detalle, lo cual dificulta el emparejamiento posterior. Para abordar este problema se aplicó *Adaptive Non-Maximal Suppression* (ANMS), una técnica que selecciona un subconjunto de keypoints manteniendo aquellos con mayor respuesta y mejor distribuidos espacialmente.

De esta forma se obtiene un conjunto reducido de puntos más representativos y uniformemente distribuidos en la imagen, lo que facilita tanto el matching como la estimación de homografías.

II-C. Matching de características

Una vez extraídos los descriptores SIFT, el siguiente paso fue establecer correspondencias entre imágenes. Para ello se probaron dos variantes del algoritmo *Brute Force Matcher* (BFMatcher):

- **BFMatcher con cross-check:** compara cada descriptor de una imagen con todos los de la otra y conserva solo las coincidencias que sean mutuas. Esto garantiza correspondencias simétricas, pero puede descartar matches válidos y reducir la cantidad final.
- **BFMatcher con prueba de razón de Lowe:** para cada descriptor se seleccionan los dos vecinos más cercanos y se acepta el match únicamente si se cumple

$$\frac{\|d - n_1\|}{\|d - n_2\|} < \tau,$$

donde n_1 y n_2 son los dos descriptores más cercanos y τ es el umbral (*ratio_thresh*). Este criterio filtra gran parte de los outliers y mejora la confiabilidad de las correspondencias.

En la práctica, el método de Lowe mostró un mejor balance entre cantidad y calidad de matches, aunque dependió del valor elegido para τ . Por este motivo se decidió continuar con esta segunda estrategia en las siguientes etapas del trabajo.

II-D. Selección manual de puntos

Además de los emparejamientos automáticos, se implementó una herramienta interactiva para seleccionar correspondencias manuales entre imágenes. Para ello se utilizó la función `pick_points_cv`, basada en *callbacks* de OpenCV, que

permite al usuario hacer clic sobre las imágenes y registrar las coordenadas de un conjunto de puntos. El sistema muestra marcadores numerados en cada clic, admite deshacer la última selección y finaliza cuando se alcanza la cantidad deseada de puntos. De esta manera, fue posible generar homografías a partir de puntos seleccionados manualmente, lo que permitió validar y comparar los resultados obtenidos con el proceso automático.

II-E. DLT

Para estimar la homografía entre imágenes se implementó el algoritmo *Direct Linear Transform* (DLT). Una homografía proyectiva se expresa como:

$$x' \sim Hx, \quad H \in R^{3 \times 3},$$

donde x y x' son coordenadas homogéneas.

Cada correspondencia $(x, y) \leftrightarrow (x', y')$ aporta dos ecuaciones lineales, que se agrupan en un sistema de la forma:

$$Ah = 0,$$

donde h es el vector de parámetros de H . El sistema se resuelve mediante descomposición en valores singulares (SVD), tomando como solución el vector asociado al menor valor singular.

En este trabajo, al seleccionar manualmente cuatro puntos, el sistema resulta determinado y la homografía se recupera de manera exacta. Cuando se emplean más de cuatro correspondencias automáticas, el sistema pasa a ser sobre-determinado y SVD entrega la mejor aproximación en el sentido de mínimos cuadrados.

II-F. RANSAC (Random Sample Consensus)

El método RANSAC se utilizó para estimar homografías de manera robusta a la presencia de outliers en los matches. En cada iteración, se selecciona un subconjunto mínimo de cuatro correspondencias, se calcula una homografía candidata y se evalúan los *inliers*, definidos como aquellos que cumplen:

$$\|x' - Hx\| < \epsilon,$$

donde ϵ es el umbral de error de reproyección.

El modelo con mayor cantidad de inliers se considera la mejor estimación y, a partir de esos puntos consistentes, se recalcula la homografía final. Este enfoque permitió descartar correspondencias erróneas y mejorar notablemente la calidad de las panorámicas obtenidas, especialmente frente a matches espurios que afectaban al alineamiento cuando se aplicaba solo DLT.

II-G. Cálculo del tamaño óptimo de la imagen final

Luego de estimar las homografías, el siguiente paso consiste en determinar el tamaño del lienzo donde se ensamblarán las imágenes. El procedimiento seguido fue:

1. Tomar las cuatro esquinas de cada imagen y transformarlas al marco de la imagen ancla mediante la homografía correspondiente.

2. Calcular los valores extremos de estas esquinas transformadas, lo que permite definir el *bounding box* de la panorámica.
3. Dado que algunas coordenadas pueden resultar negativas, aplicar una traslación para asegurar que todas las imágenes queden dentro del lienzo en coordenadas positivas.
4. Con los extremos corregidos, definir el ancho y alto finales de la panorámica de manera que no sobren bordes vacíos ni se recorten regiones relevantes.

De esta forma, se obtiene un lienzo compacto y ajustado, garantizando que la composición final sea eficiente en espacio y visualmente consistente.

II-H. Warping y Blending

Una vez estimadas las homografías, el siguiente paso fue proyectar las imágenes al marco de referencia de la imagen ancla. Para ello se aplicó un *warping* definido por:

$$\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} \sim H \begin{bmatrix} x \\ y \\ 1 \end{bmatrix},$$

donde cada píxel (x, y) de la imagen original se transforma en (u, v) en el lienzo común.

En la etapa de *blending* se abordaron dos problemas principales: (i) diferencias de exposición entre imágenes, y (ii) la aparición de costuras visibles en las zonas de solapamiento. Para el primer caso se aplicó un ajuste de exposición basado en las medianas por canal en las regiones de superposición. Para el segundo se utilizó *feather blending* mediante un *distance transform*, lo que suavizó las transiciones en los bordes y permitió obtener panorámicas más naturales.




Figura 1. Pipeline en “C”: SIFT → ANMS → Matching → H (DLT+RANSAC) → lienzo (bbox+T) → warping → blending → panorámica.

III. RESULTADOS

III-A. Efecto de ANMS sobre los keypoints

Como se observa en las Figuras 2 y 3, antes de aplicar ANMS los *keypoints* se concentran en zonas con mucha textura o bordes de objetos, dejando vacías regiones homogéneas. Tras aplicar ANMS (selección adaptativa de máximos locales), se reduce la cantidad total de puntos (aproximadamente 5000 → 1000), pero su distribución espacial mejora notablemente: los puntos quedan más repartidos en toda la imagen, lo que favorece el *matching* y la estimación de homografías.

Este filtrado tiene un impacto positivo en la robustez del emparejamiento, ya que zonas que antes no estaban representadas ahora sí lo están, ayudando a disminuir los errores

generados por *matches* locales muy similares o ambiguos en regiones densas.



Figura 2. Distribución de keypoints detectados con SIFT antes de aplicar ANMS (Imagen 2). Se observa una alta concentración en regiones texturadas.



Figura 3. Distribución de keypoints después de aplicar ANMS. La cantidad total se reduce pero quedan mejor distribuidos espacialmente.

III-B. Matching de características

En esta etapa se compararon dos estrategias de emparejamiento de descriptores: *BFMatcher con validación cruzada (cross-check)* y la *prueba de razón de Lowe*.

Los resultados mostraron que el método de Lowe brinda un mejor compromiso entre la cantidad y la calidad de correspondencias. Se probó con diferentes valores de *ratio_thresh*,

observándose el siguiente comportamiento en la imagen del cuadro:

- Cross-check: 261 matches.
- Ratio 0.55: 38 matches.
- Ratio 0.65: 69 matches.
- Ratio 0.70: 92 matches.
- Ratio 0.75: 129 matches.
- Ratio 0.85: 256 matches.
- Ratio 0.90: 376 matches.

En la práctica, se eligió trabajar con un umbral **ratio** = **0.8**, que ofrece una cantidad suficiente de puntos para que RANSAC logre buena convergencia sin comprometer la calidad de las correspondencias.

Además, para el caso del *DLT manual*, se empleó la herramienta de selección manual de puntos, como se ilustra en la Figura 4, lo que permitió construir homografías de forma controlada y comparar con el otro proceso.




Figura 4. Ejemplo de correspondencias seleccionadas manualmente entre la imagen ancla y la imagen derecha.

III-C. Homografía estimada con DLT (manual y automática)

Las matrices obtenidas para la estimación de homografías del cuadro se presentan a continuación. En este caso se muestra únicamente la homografía entre la imagen ancla y la izquierda, ya que permite una comparación más clara entre los métodos.

III-C0a. Homografía manual (DLT directo):

$$H_{A \rightarrow Left} = \begin{bmatrix} 0,921 & 0,139 & 1111,34 \\ -0,102 & 0,750 & 411,13 \\ 1,20 \times 10^{-4} & -4,10 \times 10^{-5} & 1 \end{bmatrix} \quad (1)$$

III-C0b. Homografía automática (DLT + RANSAC):

$$H_{A \rightarrow Left} = \begin{bmatrix} 0,886 & 0,171 & 1078,88 \\ -0,135 & 0,764 & 423,70 \\ 1,03 \times 10^{-4} & -3,28 \times 10^{-5} & 1 \end{bmatrix} \quad (2)$$

Se observa que ambas aproximaciones producen matrices muy similares en estructura y magnitud, con valores lógicos: los coeficientes cercanos a la diagonal principal representan transformaciones de escala y rotación razonables, mientras que las traslaciones en la última columna reflejan desplazamientos consistentes con la geometría del problema. Esto valida la implementación del método. No obstante, la versión automática con RANSAC resulta más robusta frente a outliers en el emparejamiento, mejorando la calidad del alineamiento final.

III-D. Ajuste del tamaño del lienzo

La aplicación práctica de este procedimiento permitió reducir áreas negras innecesarias en el mosaico final. Inicialmente, al proyectar las imágenes sin traslación, algunas quedaban desplazadas y aparecían zonas vacías alrededor de la panorámica. Tras calcular el *bounding box* y aplicar la traslación adecuada, se obtuvo un lienzo más compacto: todas las imágenes quedaron contenidas dentro del área útil y se aprovecharon mejor los píxeles disponibles.

Visualmente, esto se refleja en un encuadre más equilibrado, sin márgenes excesivos ni regiones recortadas. El ajuste también facilitó el *blending* posterior, ya que las transiciones ocurrieron dentro de una región bien delimitada.

III-E. Evaluación cuantitativa de errores de reproyección

Además de la comparación visual de homografías, se midió el error de reproyección en píxeles para los pares de imágenes Ancla→Izquierda y Ancla→Derecha. El error se calculó proyectando cada punto (x, y) de la imagen origen mediante la homografía H y comparando con su correspondencia real en la imagen destino. Se reportan estadísticas agregadas (media, mediana, RMSE, percentil 95 y máximo), así como la cantidad de *inliers* detectados por RANSAC.

Método	n	Media	Mediana	RMSE	P95	Máx.
DLT A→Left (all)	134	565.7	76.1	873.7	1757.0	2038.7
RANSAC A→Left (inliers)	34	1.56	1.23	1.83	3.19	3.75
DLT A→Right (all)	104	832.1	717.7	1104.2	2048.2	2198.2
RANSAC A→Right (inliers)	11	1.32	1.26	1.51	2.60	3.22

Cuadro I

ERRORES DE REPROYECCIÓN (PX) EN CORRESPONDENCIAS CRUDAS VS. FILTRADAS POR RANSAC.

Asimismo, el conteo de *inliers*/outliers revela que en el caso A→Left sólo el 25 % de los matches se consideran válidos, mientras que en A→Right apenas un 10.6 %. Esto confirma que el uso de RANSAC es crítico para descartar outliers y obtener homografías consistentes.

Finalmente, se evaluó también el *error simétrico de transferencia* (proyectando en ambas direcciones). En este caso, los valores para DLT sin filtrado superaron los 1000–2000 píxeles de media, mientras que para RANSAC con *inliers* se redujeron a valores cercanos a 3–4 píxeles. Estos resultados cuantitativos refuerzan la observación visual: RANSAC mejora notablemente la robustez y precisión del alineamiento.

III-F. Warping y construcción de la panorámica

Una vez estimadas las homografías entre la imagen ancla y las imágenes izquierda y derecha, se procedió a proyectarlas hacia un mismo lienzo de referencia. Para ello se invirtieron las transformaciones obtenidas con RANSAC, de modo que ambas vistas pudieran alinearse en el marco de la imagen central.

El lienzo resultante se definió considerando las esquinas transformadas de todas las imágenes, asegurando que ninguna región relevante quedara fuera de la panorámica.

En una segunda etapa se corrigieron las diferencias de exposición entre imágenes, ajustando las intensidades de color

a partir de la comparación de las zonas de solapamiento. Esto permitió reducir las variaciones de iluminación y obtener un aspecto más uniforme en la composición.

Finalmente, para suavizar las transiciones en las áreas de superposición, se aplicó una técnica de *feather blending* basada en mapas de distancia. Este procedimiento otorga mayor peso a los píxeles del interior de cada imagen y menor peso en los bordes, logrando una transición gradual y natural en las costuras.

El resultado fue una panorámica continua en la que las tres imágenes se integran en un único lienzo, con corrección de exposición y uniones visualmente más suaves.

III-F0a. Evidencia visual del *blending*. La Figura 5 compara la panorámica *sin blending* (composición directa) y *con feather blending*. Se observan bordes menos notorios y mejor continuidad de color en las zonas solapadas.



Figura 5. Panorámica sin (izq.) y con (der.) feather blending. El suavizado reduce discontinuidades de exposición y *ghosting* leve.

Artefactos remanentes: se detectaron leves *ghostings* en objetos en movimiento y pequeñas curvaturas en bordes rectos cerca de los extremos del lienzo, atribuibles a errores de homografía locales y a diferencias de paralaje.

III-G. Comparación de panorámicas

En la Figura 6 se comparan dos panorámicas finales: (i) usando homografías de DLT manual y (ii) usando DLT automático + RANSAC. Visualmente, la versión automática presenta: (a) mejores alineamientos en líneas estructurales, (b) menos costuras visibles tras el *blending* y (c) menor dependencia de puntos manuales.



Figura 6. Comparación visual del warping A→Left: (arriba) homografía manual (DLT directo) y (abajo) homografía automática (DLT + RANSAC). Se aprecian menores desalineamientos en bordes y líneas rectas con la versión automática.

III-H. Conjunto de imágenes propuesto

Además de los conjuntos principales provistos por la cátedra, se evaluó un conjunto de imágenes propio. Las capturas se realizaron asegurando un solapamiento de aproximadamente 40 % entre vistas consecutivas y seleccionando como imagen central una toma “ancla” desde la cual se obtuvieron las demás. Este criterio cumple con la condición de superposición mínima requerida y con la hipótesis de plano dominante: los edificios se encuentran lo suficientemente alejados para aproximar sus características a un mismo plano proyectivo.

El conjunto propio presenta mayores desafíos debido a variaciones de exposición (diferencias de iluminación entre tomas) y texturas repetitivas (fachadas, toldos, baldosas). Esto estresa tanto el *ratio test* como el *blending*: (i) con un *ratio* demasiado alto aparecen más outliers que degradan la convergencia de RANSAC; (ii) el *feather blending* suaviza bordes pero en escenas con diferencias de iluminación más severas sería conveniente un *multi-band blending*.

Las panorámicas resultantes se muestran en la Figura 8, donde se aprecian las limitaciones y ventajas del método sobre este nuevo escenario.



Figura 7. Conjunto adicional



Figura 8. Panorámica del conjunto adicional con mayores diferencias de exposición.

IV. CONCLUSIONES

IV-A. Síntesis y hallazgos

Los resultados muestran que la variante automática **DLT + RANSAC** produce homografías significativamente más precisas y robustas que el DLT directo con correspondencias crudas. La etapa de **ANMS** contribuyó a una mejor cobertura espacial de puntos clave, mejorando la calidad del matching y la estabilidad de las homografías. El **cálculo del lienzo óptimo** mediante las esquinas transformadas y la traslación T evitó bordes vacíos innecesarios y facilitó un *warping* más limpio. Finalmente, el **feather blending** con corrección de exposición por medianas redujo costuras y discontinuidades de color, si bien en escenas con diferencias de iluminación más severas todavía quedan artefactos sutiles.

IV-B. Limitaciones observadas

- **Paralaje/escenas no planas:** si la geometría no es aproximadamente planar (o está “en el infinito”), aparecen curvaturas y *ghosting* local.
- **Variaciones de exposición:** el feather blending mejora bordes, pero no corrige del todo diferencias severas de iluminación.

- **Escenas dinámicas:** objetos en movimiento generan inconsistencias temporales que se reflejan en solapamientos borrosos.